

Макарчук Алексей

Лекция 5. Разбор классических DS метрик в футболе

xG, xP, xT, xA, OBV, Vaer, EPV - что означают и как применять в анализе

План

01

Лекция:
18:00 - 19:10
70 минут

02

QA сессия:
19:10 - 19:25
15 минут

03

Перерыв:
19:25 - 19:30
5 минут

04

Семинар:
19:30 - 20:15
45 минут





У тебя есть лекция?

Лучше. У меня есть план лекции.



Типы данных в футболе



Ивентовые данные



Трекинговые данные



Датасеты (tracking+event)

Данные по ивентам:

- StatsBomb Open Data
 - ивентовые данные (2 433 матча)
 - Statsbomb360 с бродкаст данными (295 матча)
- Wyscout Soccer Event Dataset (1941 матча)

df.head()

	id	index	period	timestamp	minute	second	possession	duration	match_id	type_id	...	ball_recovery_recovery_failure	foul_won_defensive	pass_backheel	block_offensive	shot_one_on_one	off_camera	substitution_replacem
0	0d8dcda-710e-4b8b-8692-4d75e6d2d334	1	1	00:00:00	0	0	1	0.000000	19720	35	...	NaN	NaN	NaN	NaN	NaN	NaN	
1	f8823c57-870e-4b84-81a3-0a21abc6524c	2	1	00:00:00	0	0	1	0.000000	19720	35	...	NaN	NaN	NaN	NaN	NaN	NaN	
2	0730284c-3816-4112-9a78-ebb4367708f3	3	1	00:00:00	0	0	1	0.000000	19720	18	...	NaN	NaN	NaN	NaN	NaN	NaN	
3	a21f5680-ca44-45c9-bc1e-15737d559b3b	4	1	00:00:00	0	0	1	0.000000	19720	18	...	NaN	NaN	NaN	NaN	NaN	NaN	
4	d4b3c3ae-ed78-42f1-81e8-b961ee77281e	5	1	00:00:01.289000	0	1	2	1.504113	19720	30	...	NaN	NaN	NaN	NaN	NaN	NaN	

5 rows x 63 columns

Полные трекинг данные:

- PFF FC's 2022 World Cup Dataset (64 матча)
- metrics sports (3 матча)
- skillcorner broadcast без ивентов (9 матчей)

Статистика:

- FBREF (StatsPerform Opta)

Kloppy



```

from kloppy import sportec

# load
dataset = sportec.load_open_event_data(match_id="J03WMX")

# filter & transform
goals = (
    dataset
    .filter("shot.goal")
    .transform(
        to_coordinate_system="opta",
        to_orientation="STATIC_HOME_AWAY"
    )
)

# export
goals.to_df(
    "player",
    "coordinates_*",
    assist=lambda event: event.prev("pass"),
    engine="polars"
)

```

Provider	Event Data	Tracking Data	Public Data	Docs	Notes
DataFactory	✓			↗	
Hawkeye (2D)		✓		↗	Joint tracking data is not yet supported
Impect	✓		↗	↗	
Metrica	✓	✓	↗	↗	
PFF	✗	✓	↗	↗	
SecondSpectrum	✗	✓		↗	
Signalify		✓		↗	
SkillCorner		✓	↗	↗	
Sportec	✓	✓	↗	↗	
StatsBomb	✓		↗	↗	Includes 360 freeze frame data support
Stats Perform	✓	✓		↗	Includes support for MA1, MA3, and MA25 data feeds
Opta	✓			↗	Includes support for F7, F24 and F73 XML data feeds
Tracab		✓		↗	
Wyscout	✓		↗	↗	Includes support for v2 and v3 data

worldfootballR



```
prem_2020_team_shooting <- fb_league_stats(  
  country = "ENG",  
  gender = "M",  
  season_end_year = 2020,  
  tier = "1st",  
  non_dom_league_url = NA,  
  stat_type = "shooting",  
  team_or_player = "team"  
)  
dplyr::glimpse(prem_2020_team_shooting)
```

Usage

Package vignettes have been built to help you get started with the package.

- For functions to extract data from FBref, see [here](#)
- For functions to extract data from Transfermarkt, see [here](#)
- For functions to extract data from Understat, see [here](#)
- For functions to extract data for international matches from FBref, see [here](#)
- For functions to load pre-scraped data, see [here](#)

Loading Data



Since the release of `v0.5.3`, the library now supports very rapid loading of pre-collected data through the use of `load_` functions.

The data available for loading is stored in the `worldfootballR_data` repository. The repo can be found [here](#).

Head to the vignette [here](#) to see examples of which data is available for rapid loading.

xG (2012)



xG



The xG Philosophy 


@xGPhilosophy

PSG (0.98) 5-2 (1.73) Chelsea

xP



xP



xT

Expected Threat (xT): The Best Offensive Metric So Far

THE CONCEPT: What is Expected Threat (xT)?

Valuing Every Action

xT measures how any action on the pitch increases or decreases the probability of scoring.

The Pitch is a Grid

The field is divided into zones, each with a pre-calculated goal-scoring threat value.

Gaining Ground = Gaining Value

An action's xT is the change in value from its start zone to its end zone.

footballytics

THE ADVANTAGE: Why is xT Superior?

TRADITIONAL STATS (Goals/Assists)

Captures only ~1% of actions

EXPECTED THREAT (xT)

Evaluates the other 99%

Beyond Final Actions

Unlike xG/xA, xT credits players for crucial buildup play, not just the final shot or assist.

Rewarding the Entire Team

It recognizes the value of the pass that initiates an attack, not just the one before the goal.

A Holistic View of Offense

It evaluates the entire passing game and space creation, rewarding consistency over rare, flashy plays.

THE APPLICATION: How is xT Used?

Smarter Scouting

Identify undervalued players whose contributions are invisible to traditional statistics.

Tactical Team Analysis


Pinpoint exactly which zones and players generate the most offensive threat for a team.

Beyond Passing

The xT grid can also be used to value dribbles or defensive duels in critical zones.



xT



Средний показатель Премьер-лиги

Когда игрок находится с мячом в выделенной зоне, какое действие он предпримет дальше?

Перемещение: 77% , согласно карте.

Удары: 23% , попадания в корзину составляют 3% .

Наведите курсор/щелкните, чтобы сменить зону!

Классная статья с объяснением

$$\mathbf{xT}_{x,y} = (s_{x,y} \times g_{x,y}) + (m_{x,y} \times \sum_{z=1}^{16} \sum_{w=1}^{12} T_{(x,y) \rightarrow (z,w)} \mathbf{xT}_{z,w})$$

- $\mathbf{xT}(x, y)$ - опасность зоны (x, y)
- $s(x, y)$ - исторический % ударов с зоны (x, y)
- $g(x, y)$ - xG удара с зоны (x, y)
- $m(x, y)$ - исторический % передвижения с зоны (x, y)
- $T(x, y) \rightarrow (z, w)$ - историческое распределение вероятностей перемещения из зоны (x, y) в другие зоны
- Рекурсивно вычисляем для $N \rightarrow \inf$, начиная с $N = 0$; $T(x, y) = 0$

$$\mathbb{P}(X_{n+1} = s_{n+1} | X_n = s_n, X_{n-1} = s_{n-1}, X_{n-2} = s_{n-2}, \dots) = \mathbb{P}(X_{n+1} = s_{n+1} | X_n = s_n)$$



Производные (xA, xGChain, .*xG.*)

Приблизительно отсортированы по популярности:

xA - Модель ожидаемых ассистов от Stats Perform. Учитывает факторы, влияющие на шанс, что передача станет ассистом.

xGChain - Суммарное значение xG всех владений с ударом, в которых участвовал игрок. Финальный xG каждой атаки распределяется между всеми участниками комбинации.

.*xG.* - Еще одна модификация xG



Составные метрики



ЕСЛИ ДОЛГО ВСМАТРИВАТЬСЯ В
БЕЗДНУ - БЕЗДНА НАЧНЕТ ВСМАТРИВАТЬСЯ В ТЕБЯ

NAME	CREATOR	DEBUT	METHOD	WINDOW	OFF-BALL INFORMATION
Markov Chains	S. Rudd	2011	Markov chain	One possession	Defensive states tagged in event data
Possession-Based Model	N. Mackay	2016	Logistic regression and GAM	One possession	None
Expected Threat (xT)	K. Singh	2019	Markov-like	Next 5 actions (goal for)	None
Valuing Actions by Estimating Probabilities (VAEP)	KU Leuven DTAI	2019	Gradient-boosted trees	Next 10 actions (goal for or against)	Possession history proxies
Expected Possession Value (EPV)	J. Fernández et al.	2019	Multiple models	Next goal (for or against) or end of half	Full tracking data
Possession Value (PV)	Stats Perform	2019	Gradient-boosted trees	Next 10 seconds (goal for)	Possession history proxies
Goals Added (G+)	American Soccer Analysis	2020	Gradient-boosted trees	Two possessions	Possession history proxies
On-Ball Value (OBV)	StatsBomb	2021	Gradient-boosted trees	Two possessions	Broadcast freeze frames (in development)

OBV (2021 statsbomb)



- В отличие от xT, учитывает не только шансы забить, но и вероятность пропустить.
- Каждое действие оценивается по ΔxG (пропустить + забить)
- Группировка ΔxG по всем on-ball действиям по игрокам (set ~20)
- Нормирование в $[0, 1]$ по позициям, получение "рейтинга" OBV игрока за матч + можно декомпозировать по действиям
- Усредненный OBV по матчам - "рейтинг" игрока за сезон

Vaep (2019 SciSports)

SPADL (атрибуты действий)

АТРИБУТ	ОПИСАНИЕ
StartTime	Момент времени когда действие началось
EndTime	Момент времени когда действие закончилось
StartLoc	Координаты поля в начальный момент
EndLoc	Координаты поля в конечный момент
Player	Имя игрока выполняющего действие
Team	Название команды
ActionType	Тип действия (согласно градации на 21 действие)
BodyPart	Часть тела
Result	Результат действия (успешное или нет)

SPADL (типы действий)

ТИП ДЕЙСТВИЯ	ОПИСАНИЕ	УСПЕШНОСТЬ ДЕЙСТВИЯ	ДОПОЛНИТЕЛЬНЫЙ ТИП ИСХОДА
Pass	Пас на открытого игрока	Достигает партнера	Офсайд
Cross	Навес в штрафную	Достигает партнера	Офсайд
Throw-in	Вбрасывание (из аута)	Достигает партнера	
Crossed corner	Навес с углового в штрафную	Достигает партнера	Офсайд
Short corner	Розыгрыш углового	Достигает партнера	Офсайд
Crossed free-kick	Навес со штрафного в штрафную	Достигает партнера	Офсайд
Short free-kick	Розыгрыш штрафного	Достигает партнера	Офсайд
Take on	Попытка обыграть соперника	Сохраняется владение	
Foul	Фол	Всегда успешное	Желтая или красная
Tackle	Подкат	Восстановление владения	Желтая или красная
Interception	Перехват мяча	Всегда успешное	
Shot	Удар (не пенальти и не штрафной)	Гол	Автогол
Penalty shot	Пенальти	Гол	Автогол
Free-kick shot	Удар со штрафного	Гол	Автогол
Keeper save	Голкипер делает сейв после удара по воротам	Всегда успешное	
Keeper claim	Голкипер ловит мяч намертво после навеса (игра на выходах)	Не выронил мяч	
Keeper punch	Голкипер выбивает мяч после навеса (игра на выходах)	Всегда успешное	
Keeper pick-up	Голкипер забирает мяч в руки	Всегда успешное	
Clearance	Вынос мяча (безадресный)	Владение сохраняется	
Bad touch	Неудачный прием мяча, после которого мяч был потерян	Всегда неуспешное	
Dribble	Игрок проходит 3 и более метров с мячом (ведение мяча на дриблинге)	Всегда успешное	

Vaep (2019 SciSports)

Элемент	Обозначение / Формула	Комментарий
Действие (SPADL)	$a_i = (\text{StartTime}, \text{EndTime}, \text{StartLoc}, \text{EndLoc}, \text{Player}, \text{Team}, \text{Type}, \text{BodyPart}, \text{Result})$	9 атрибутов для описания действия
Набор действий	$A_i = \langle a_1, a_2, \dots, a_{22} \rangle$, где одно из действий с мячом, а остальные без	В практической реализации $A_i = \langle a_1 \rangle$ ввиду отсутствия трекинговых данных
Игровое состояние	$G_i = \langle A_1, A_2, \dots, A_i \rangle$	Последовательность всех действий до момента i
Окно контекста	$S_i = (A_{i-2}, A_{i-1}, A_i)$	Используется при формировании признаков (окно = 3 действия)
Вероятность забить / пропустить	$P_{\text{score}}(S_i), P_{\text{concede}}(S_i)$	Вероятность забить / пропустить в ближайшие $k = 10$ действий
Изменение вероятностей из-за действия	$\Delta P_{\text{score}} = P_{\text{score}}(S_i) - P_{\text{score}}(S_{i-1})$ $\Delta P_{\text{concede}} = P_{\text{concede}}(S_i) - P_{\text{concede}}(S_{i-1})$	Показывает, как действие изменило перспективу команды
Ценность действия (value)	$V(a_i) = \Delta P_{\text{score}} - \Delta P_{\text{concede}}$	Если команда сохраняет владение; при потере — знаки меняются
Интерпретация $V(a_i)$	$V > 0$ — действие улучшило позицию команды $V < 0$ — действие ухудшило положение	Пример: удачный дриблинг $\rightarrow +0.04$, потеря $\rightarrow -0.05$
Оценка действия моделью	$\hat{P}_{\text{score}}(S_i)$ и $\hat{P}_{\text{concede}}(S_i)$ предсказывается классификатором (Random Forest)	Обучение на бинарной задаче: забьёт ли команда в ближайшие 10 действий
Цель обучения	минимизация log-loss / улучшение ROC-AUC	Наилучший результат — ROC AUC = 0.797
Использование	Рейтинг игрока за период $T = R_p = \frac{90}{T_p} \sum_{a_i \in A_p^T} V(a_i)$	Сумма ценностей всех действий, нормированная на 90 мин


Таблица 1: Основные элементы модели оценки действий в футболе (SPADL / VAEP)

- Рассматривается команда, владеющая мячом.
- Берутся 3 предыдущих on-ball действия команды и подаются в модель.
- Модель возвращает вероятность забить (score) и пропустить (concede) гол за следующие 10 действий.
- Таргет: бинарная классификация (0, 1) забит или пропущен гол в окне из 10 следующих действий.
- Vaep считается аналогично OBV и рассчитывает $\Delta P_{\text{score}} - \Delta P_{\text{concede}}$

EPV



5.5 (AS)	Принятие решение игроком	Оценивает вероятность того, что игрок с мячом выберет одно из трех действий: пас, ведение или удар.	Мелкая нейронная сеть, состоящая из двух полностью связанных слоев, за каждым из которых следует слой функций активации ReLU, с выходом из одного нейрона, которому предшествует функция активации sigmoid	Вектор признаков, описывающих состояние	Вектор из трех вероятностей (для паса, ведения, удара), сумма которых равна 1.
5.4 (ES)	xG	Оценивает вероятность забить гол при ударе по воротам	Мелкая нейронная сеть, состоящая из двух полностью связанных слоев, за каждым из которых следует слой функций активации ReLU, с выходом из одного нейрона, которому предшествует функция активации sigmoid	Вектор признаков, описывающих состояние	Одно число — вероятность забить гол
5.2 (DP)	Вероятность успешности дриблинга	Оценивает вероятность, что игрок сохранит владение после ведения мяча в течение 1 секунды.	Мелкая нейронная сеть, состоящая из двух полностью связанных слоев, за каждым из которых следует слой функций активации ReLU, с выходом из одного нейрона, которому предшествует функция активации sigmoid	Вектор признаков, описывающих состояние	Одно число — вероятность успешного ведения (значение от 0 до 1).
5.3 (DE)	Ценность владения после успешного дриблинга Ценность владения после неуспешного дриблинга	Оценивает EPV после успешного или неудачного ведения. Обучаются две отдельные модели	Мелкая нейронная сеть, состоящая из двух полностью связанных слоев, за каждым из которых следует слой функций активации ReLU, с выходом из одного нейрона, которому предшествует функция активации sigmoid	Вектор признаков, описывающих состояние	Одно число — EPV после ведения. Значение в диапазоне [-1, 1]
5.1.3 (PP)	Вероятность отдать пас в каждую точку поля	Оценивает, с какой вероятностью игрок выберет передачу в каждую из возможных точек поля.	Полносверточная нейронная сеть (лист 2)	13 слоев пространственных признаков. Каждый слой — это матрица 104x68, представляющая все поле.	Поверхность 104x68, где значение в каждой ячейке — это вероятность того, что игрок направит пас именно в эту точку.
5.1.1 (PS)	Вероятность успешности паса в каждую точку поля	Оценивает вероятность того, что пас в каждую точку поля будет успешным	Полносверточная нейронная сеть (лист 2)	13 слоев пространственных признаков. Каждый слой — это матрица 104x68, представляющая все поле.	Поверхность 104x68, где значение в каждой ячейке — это вероятность успешного паса в соответствующую точку поля.
5.1.2 (PE)	Ценность владения после успешного паса в данную точку Ценность владения после неуспешного паса в данную точку	Оценивает EPV после успешного или неудачного паса. Обучаются две отдельные модели	Полносверточная нейронная сеть (лист 2)	16 различных слоев с информацией, которая были в модели вероятности успешного прохождения. Кроме того, мы добавляем серию слоев с концепциями перигрианных игроков и динамическими линиями давления и поверхностью вероятности прохождения	Поверхность 104x68, где значение в каждой ячейке — это EPV после паса в эту точку.



Всем спасибо за внимание!

