

Макарчук Алексей

Лекция 7. Использование методов NLP как инструмент поддержки принятия решений в скаутинге

План

01

Лекция:
18:00 - 19:10
70 минут

02

QA сессия:
19:10 - 19:25
15 минут



Данные со структурой



Скаутские отчеты

Что общего между 200 000 скаутских отчетов и нерешенной задачей поиска игрока?

- У футбольного клуба может быть огромный массив скаутских отчетов: за несколько лет это десятки и даже сотни тысяч текстов
- Данные часто не структурированы
- Необходимо учитывать комментарии скаута
- Сложно проводить аналитику с неструктурированными данными: фильтровать, агрегировать, сравнивать и превращать в shortlist кандидатов

ОТЧЕТ СКАУТА TRYOUT

ФИО _____
ДАТА РОЖДЕНИЯ _____
КЛУБ _____

Передача Удар
Контроль мяча Игра без мяча
Креативность Коммуникация
Сила Выносливость
Скорость Игра 1x1 (для атакующих)
Игра 1x1 (отбор, для защитников)

Новостной фон

Дополнительный контекст для анализа:

- травмы
- дисциплинарные эпизоды
- конфликты
- изменение роли в команде
- рост доверия со стороны тренера

Получение обзорного профиля по игроку до проведения глубокого скаутинга

3 АПРЕЛЯ 2026

10:35 Игрок «Зенита» Ерохин: мы выступаем в роли догоняющих – уже нельзя терять очки

10:10 «В команде его не будет». Стала известна реакция Челестини на ссору с Мойзесом • 5 эксклюзив

10:08 Орлов: разве может тренер вести себя так, как Карпин? Это же верх беспределщины • 1

09:41 «Рад всех видеть на тренировке». Круговой опубликовал фото с Мойзесом • Фото

09:30 Расписание матчей 23-го тура чемпионата России по футболу сезона-2025/2026 • 1

09:15 Стало известно, почему Алексей Березуцкий покинул штаб Челестини в ЦСКА • 11 эксклюзив

01:39 The Sun сравнила Аршавина с Брэдом Питтом и Ди Каприо после его поездки в Узбекистан • 3

00:27 Эдуард Мор назвал фаворита матча 23-го тура РПЛ между «Спартак» и «Локомотивом»

00:10 «Главное не начудить с составом». Семшов — о «Спартаке» перед матчем с «Локомотивом» в РПЛ • 2

2 АПРЕЛЯ 2026

23:52 Антон Митрюшкин высказался после переподписания контракта с «Локомотивом»

21:23 «Кто об этом не мечтает?» Бояринцев — о своих тренерских перспективах и «Спартаке» • 3

21:00 «У всех логистика сложная». Семак — об игроках сборных и составе на матч 23-го тура РПЛ

20:01 Шесть футболистов и Талалаев пропустят 23-й тур РПЛ • 12

19:55 Кузнецов: если ЦСКА проиграет «Акрону», будет катастрофа • 9

Профильные источники

transfermarkt.world

LIVE 1

Введите текст для поиска...

🔍

👤

🔖

🛡️

👤 ЛОГИН

ОТКРОЙТЕ ДЛЯ СЕБЯ

ТРАНСФЕРЫ И СЛУХИ

РЫНОЧНЫЕ СТОИМОСТИ

СОРЕВНОВАНИЯ

СТАТИСТИКА

ФОРУМЫ

ИГРЫ

☰

В ЦЕНТРЕ ВНИМАНИЯ

● ● ● ● ●

СТРАНЫ ПОСТСОВЕТСКОГО ПРОСТРАНСТВА

Требуется скауты данных для Transfermarkt на исторические сезоны

Все топ-лиги

What's My Value?

Стать тренером сборной

Состав свой состав на Чемпионат мира 2026

НА ИСТОРИЧЕСКИЕ СЕЗОНЫ

Требуется скауты данных на страны постсоветского пространства

Результаты

САМЫЕ ПОПУЛЯРНЫЕ ИГРОКИ

Cristiano Ronaldo

Стоимость: 12,00 млн €

#1

Аль-Наср

Enter Person, Team, Section, etc

Search

Players Clubs Competitions Matches Awards Countries Stathead Mailing List Full Site Menu Below

Son Heung-min

손흥민

Position: FW-MF (AM-WM) • Footed: Right

183cm, 76kg (6-0, 168lb)

Born: July 8, 1992 (Age: 33-269d) in Chuncheon, Korea Republic 🇰🇷

More Player Info

2025

MP

Min

Goals

Assists

MLS

5

428

0

2

CCC

4

286

1

4

* see our coverage note

Son Heung-min Overview

Stats by Competition

Match Logs

Goal Logs

Stathead/Compare

Los Angeles FC

Korea Republic

On this page:

Last 5 Matches

Leaderboard Appearances, Awards, and Honors

Player News

Wages

Standard Stats

Additional Resources

Shooting

Full Site Menu

Playing Time

Miscellaneous Stats

Player Club Summary

Competition Types

All Competitions

Domestic Leagues

Domestic Cups

International Cups


National Team

Sign up for the free FBref Mailing List and get curated stats, news, and updates about the FBref site to your inbox every day.

Sign Up For Free

Оцифровать “характер”

12 MARCH 2019



JUVENTUS
3-0
(3-2) 

C. RONALDO 27'
C. RONALDO 49'
(PEN) C. RONALDO 86'

The smart money's on
CORAL

 **Squawka**
More Than The Score

BEGAMBLEAWARE



Text Classification


Для отчета:

- Классификация по позиции: крайний защитник, опорник, вингер, центральный форвард
- Классификация по роли: «Восьмерка» с большим объемом, разыгрывающий опорник, полузащитник, нацеленный на отбор
- Классификация по степени рекомендации: приоритетная цель, шорт-лист, лонг-лист, отказ


Для новостей:

- Наличие или отсутствие травм/конфликтов
- Трансферный статус


Примеры токенизации



Text Classification



Text Classification



Embeddings from a generic
Sentence Transformer




Embeddings from a Sentence Transformer
fine-tuned with contrastive learning



Text Classification

Transfer Learning vs Zero-Shot Learning




NER + Entity Linking

Named Entity Recognition - это задача извлечения сущностей из текста.

Entity Linking - это задача понимать, что “Криштиану”, “Роналду” и “CR7” — это один и тот же entity_id.

Baseline: эвристики, регулярные выражения, словари соответствия.

На практике: сложные графовые ML-системы.



Semantic Search (RAG)


Поиск по смыслу по корпусу из отчетов

Пример запроса:


- “Нужен левый латераль с высоким участием в прессинге и хорошим дриблингом”

Retrieval (Semanticsearch/Elasticsearch) +
Generation

LlamaParse (+Tesseract) → LangChain → Embedder
→ Qdrant → LangChain → LLM → RAGAS
(LLM-as-a-Judge)



Semantic Search (RAG)



Для оценки качества RAGAS (LLM-as-a-Judge) использует логи:

- question - вопрос пользователя (скаута)
- contexts - те чанки текста, которые Top@K по векторной базе
- answer - финальный ответ, который сгенерировала LLM на основе этих чанков

Оценка Generation:


- Faithfulness - не придумала ли модель фактов, которых не было в извлеченных отчетах
- Relevancy - LLM-судья берет сгенерированный answer и пытается придумать вопрос, на который этот текст является идеальным ответом. Затем считается векторное (семантическое) сходство с изначальным

Оценка Retrieval:

- Context Precision - проверяет, отсортированы ли найденные contexts так, что куски текста, реально содержащие ответ, находятся на первом и втором местах, а бесполезные куски - ниже.
- Context Recall - LLM-судья разбивает эталонный ответ на утверждения и проверяет, все ли они могут быть подтверждены найденным contexts


Continued Pre-Training (DAPT)

1



Разбиваем входящий текст на токены.

2



Разделяем токенизированный текст на чанки, например по n токенов в каждом чанке - это наше контекстное окно (для GPT3 контекстное окно $n = 2048$). Чем больше окно, тем длиннее контекст и тем больше информации модель учитывает при предсказании (для GPT-4o, Claude 3.5, Gemini 1.5 Pro контекстное окно 100к–200к токенов).

3

Например, если на вход приходит последовательность токенов

[Гарри, Поттер, взял, волшебную, палочку, и,...]



...то последовательность предсказаний будет такой:

Гарри → Поттер
Гарри Поттер → взял
Гарри Поттер взял → волшебную

Созданные нами чанки поступают в модель для обучения с целью: предсказать следующий токен **в каждом месте последовательности**.

Continued Pre-Training (DAPT)

4

Например, для токена «Поттер»:

Виден токен «Гарри»

Не видны «взял, волшебную, палочку,...»

При обучении трансформера, модель видит весь текст сразу, поэтому, чтобы избежать подглядывания при предсказании, применяется маскирование токенов.

5

Например, предсказываем токен после «Гарри Поттер взял».

Модель выдаёт:

волшебную: 0.78

метлу: 0.15

шапку: 0.04

котёл: 0.03

Предсказания модель делает в виде **вероятностей** для каждого возможного следующего токена (для англ языка ~ 50к токенов в словаре для GPT3)

6



Вычисляем ошибку предсказания (лосс) и применяем алгоритм обратного распространения ошибки, считаем градиенты.

7


На основе подсчитанных градиентов, обновляем параметры модели, чтобы уменьшить ошибку предсказания (лосс). Этот один шаг обучения, называется **итерацией**. Мы его повторяем, пока не пройдем по всему датасету - это называется **эпоха**.

Supervised Fine-Tune

Основные шаги LoRA (Low-Rank Adaptation):

1. Заморозить веса основной модели
2. Добавить сжатый адаптер (1-2% от размера модели)
3. Обучить только его

Необходимо от 1000 до 3000 качественных пар [Промпт] → [Ответ]



Supervised Fine-Tune


В общем случае мы говорим о r столбцах и строках на матрице размера n :

$$\Delta W = BA = \begin{pmatrix} b_{1,1} & \dots & b_{1,r} \\ b_{2,1} & \dots & b_{2,r} \\ \dots & \dots & \dots \\ b_{n-1,1} & \dots & b_{n-1,r} \\ b_{n,1} & \dots & b_{n,r} \end{pmatrix} \begin{pmatrix} a_{1,1} & a_{1,2} & \dots & a_{1,n-1} & a_{1,n} \\ \dots & \dots & \dots & \dots & \dots \\ a_{r,1} & a_{r,2} & \dots & a_{r,n-1} & a_{r,n} \end{pmatrix}$$

Каждый элемент описывается следующим образом:

$$\Delta w_{i,j} = \sum_{k=1}^r b_{i,k} a_{k,j}$$

- Нам нужно обновить не $N \times N$ элементов, а $2 \times r \times N$.
- Величина r должна быть небольшой, тогда суммарно потребуется небольшое число элементов.
- Рангом матриц A и B является r , что и формирует название метода Low-Rank Adaptation.



Всем спасибо за внимание!

