

17 АПРЕЛЯ 2026

От Excel до LLM-агента

Три слоя Data Science в футбольном скаутинге

Евгений Шевелёв

Спортивный директор · ПФК ЦСКА Москва

Что такое Sporting Director и где здесь Data Science

SD отвечает за спортивный результат клуба: трансферы, продления, продажи, пайплайн академии. Каждое решение — невозвратимое и стоит миллионов.

270

игроков в активном лонглисте

**4 млрд
рублей**

Оборот по трансферам за 2025
год

~100

ключевых решений за
трансферное окно

~\$140

расходов на LLM в неделю

Это не Google-масштаб. Это футбольный клуб, где инженеров — один, а точность решений определяет бюджет на 3 года вперёд.

Три источника неопределённости

ШУМ ДАННЫХ

400+ метрик на игрока. 23 лиги разного уровня. 4 провайдера (StatsBomb, Wyscout, SkillCorner) с разными методологиями. Лиги не сопоставимы между собой напрямую.

СУБЪЕКТИВНОСТЬ ЭКСПЕРТОВ

6 скаутов = 6 разных линеек. У одного «Strong Buy» означает одно, у другого — совершенно другое. Частота вердиктов и точность сильно различаются.

СКОРОСТЬ РЫНКА

Трансферное окно — 2 месяца. Сотни кандидатов. Конкуренты смотрят тех же игроков. Опоздал на 3 дня — игрока забрали.

Одновременно. Каждый день.

Четыре слоя — каждый решает то, что не решает соседний

4

LLM-АГЕНТ Оркестратор. 50 инструментов. Claude Opus 4.67.

3

EMBEDDING LAKE Семантический поиск по 101 972 чанкам. GigaR 2560d.

2

SCOUT CALIBRATION Bayesian LR+/LR- на 1 427 исходов. Сердце доклада.

1

PAIS — OUTLIER DETECTION Percentile + z-score на 15 310 игроков в 23 лигах.

«Сначала смотрим что произошло. Потом сравниваем с тем, что мы думали. Не наоборот.»

Player Analytics: outlier detection на 15 310 игроков

15 310

игроков в PG

~416

активных метрик

23

лиги (RPL, BRA1, ENG1, ...)

10

доменов

ИСТОЧНИКИ

StatsBomb · 205 метрик (OBV, xG chain, line-breaking passes)

Wyscout · 135 метрик (duels, progressive runs)

SkillCorner · 67 метрик (sprint/accel, HSR, peak speed)

10 доменов:

физика · пасы · угроза воротам · созидание · дриблинг · оборона · дисциплина · кроссы · владение · вратарь

Percentile + z-score vs positional peer group

CSV (23 лиги)

ETL → PG

peer group

percentile + z

tiered filter

outlier

PEER GROUP

Сопоставлять Глебова с ГК из Бундеслиги нельзя.

$\text{peer_group} = \text{position} \times \text{age_band} \times \text{league_tier}$

Min peers: 25. Если меньше — расширяем до global.

TIERED FILTER

Tier 1: $P \geq 90$ OR $P \leq 10$ (экстремумы)

Tier 2: $P \geq 85$ OR $P \leq 15$ AND $|z| > z_border$


z_border адаптивен по размеру peer group:

- 40+ peers → 1.0
- 25–39 → 1.2
- <25 → 1.5

ГЛАВНОЕ БЛЮДО

Слой 2: Bayesian Scout Calibration

Проблема: 6 скаутов = 6 разных линеек



Один и тот же игрок: у одного скаута «Strong Buy», у другого — «watch». Как принять решение?

Likelihood ratios + Bayesian update

$LR+ = P(\text{verdict}=\text{positive} \mid \text{игрок хороший}) / P(\text{verdict}=\text{positive} \mid \text{игрок плохой})$

$LR- = P(\text{verdict}=\text{negative} \mid \text{игрок хороший}) / P(\text{verdict}=\text{negative} \mid \text{игрок плохой})$

POSTERIOR (после одного скаута)

$$P(\text{good} \mid \text{verdict}) = \text{prior} \times LR / (1 + \text{prior} \times (LR - 1))$$

Несколько скаутов $LR_{\text{combined}} = LR_1 \times LR_2 \times \dots$ с correlation cap 85% (защита от зависимых мнений)

Base rate $P(\text{good}) \approx 0.24$ — из Transfer Audit 2026, 1 427 оценок

Ground truth: Transfer Audit 2026


Без истинных меток ни одна калибровка не работает. Пришлось построить исходы 1 427 оценок за 4 года.

SUCCESS	минуты $\geq 1\,800$ в более сильной лиге AND MV не упала на 30%+ <i>$\approx 8\%$ всех оценок</i>
PARTIAL	минуты 900–1 800 OR MV выросла 30%+ при низких минутах <i>$\approx 48\%$ всех оценок</i>
FLOP	минуты < 900 AND MV упала 30%+ <i>$\approx 44\%$ всех оценок</i>

Age normalization U21 median fee = $TM \times 1.50$ · 31+ = $TM \times 0.62$. 110 оценок мигрировали FLOP → PARTIAL после коррекции.

Likelihood Ratios — 6 скаутов

LR+ · во сколько раз positive вердикт сдвигает posterior



ПРИМЕР РАСЧЁТА

Кандидат LW, 22 года, RPL.
prior = 0.24

Рязанцев: positive

→ posterior = $0.24 \times 9.01 / (1 + 0.24 \times 8.01) = \mathbf{0.74}$

+ Печерица: positive

LR_comb = $9.01 \times 3.42 \times 0.85$
→ posterior = $\mathbf{0.89}$

Кондорсе: 4 параллельных > 2-3 последовательных

PIPELINE (последовательно)

Скаут 1 → watch → stop.

Скаут 2 подключается только если 1-й сказал positive. Раннее отсечение = экономия ресурсов.

21%

miss rate

58%

F1 score

CONSENSUS-4 (параллельно)

4 скаута оценивают независимо. ≥ 2 positive → рекомендовать.

Информация перемножается (log-LR сложение).

3.4%

miss rate

88.3%

F1 score

Цена: +33% отчётов. Но 17% вернувшихся «флопов» в кармане.

Embedding Lake: 101 972 чанков + RRF hybrid

101 972

embeddings в PG

2 560

GigaR dims

8

источников

<100 мс

prefetch target

RRF HYBRID RETRIEVER (AD-32)

1

FTS ru_mixed

Russian stemmer + unaccent. Точное попадание по слову.

2

Trigram match

gin_trgm_ops на транслитерированном content_latin.

3

Vector similarity

pgvector cosine. Exact scan — 2 560d > 2 000d limit для HNSW.

Reciprocal Rank Fusion: складывает ранги по всем трём ногам. Источники: сообщения SD, thinking blocks LLM, UIS-дайджесты, документы, скаутские наблюдения, агентские переписки.

Model-as-Orchestrator: LLM сам выбирает инструменты

Opus 4.6

Claude user-facing

50

tools

4

персоны (SD/GM/Board/Scout)

streaming

+ tool_use loop

БЫЛО (rule-based)

```
if msg.match(/игрок/) { ... }  
elseif msg.match(/лонглист/) { ... }  
elseif regex for «кто забил больше» { ... }  
...
```

СТАЛО (Model-as-Orchestrator)

LLM принимает сообщение + описания 50 инструментов.
Сам решает: `get_player`, `scan_league_position`,
`get_scout_consensus`, `search_semantic...`
Параллельный tool use. До 50 вызовов в одной сессии.

Интент-роутинг на regex — паттерн 2016 года. LLM function calling делает это нативно и лучше.

Cost engineering: как это не разорило клуб

ВСЁ ВМЕСТЕ

~\$140

в неделю

на Opus, Sonnet, Haiku, GigaR,
Perplexity, всю инфраструктуру

BREAKDOWN (в неделю)

User-facing Opus (streaming)	\$45–65	CC-SPEC-5 cache + auto-cache
UIS (Managed Agents Claude)	\$58	скан 116 модулей
BrainLedger (Opus Batch ×2/день)	\$6	институциональная память
Background analytics (Haiku)	\$3.35	классификация
Decision Archaeology (Batch)	\$5	извлечение исходов
RYI Phase B (daily + weekly)	\$0.50	молодёжная разведка

Prompt caching · Batch API 50% · Haiku / Sonnet / Opus routing no effort

Конкретный кейс: как слои работают вместе

SD → бот:*«Нужен левый латераль до €8M, до 24 лет, чтобы закрыл BLK_002»*

1	слой 4	LLM разбирает: position=LB, max_age=24, max_price=8M, blocker=BLK_002
2	слой 1	scan_league_position → PAIS возвращает топ-20 outlier'ов среди LB в 23 лигах
3	слой 2	get_scout_consensus на каждого → Bayes posterior для ранжирования
4	слой 3	search_semantic: «что мы писали про этих игроков полгода назад»
5	слой 4	LLM синтезирует ответ + рекомендация: 4 кандидата, top-pick с posterior 0.74

Время всего цикла ~20 секунд. Стоимость ~\$0.08.

ГЛАВНЫЙ УРОК

LLM — это не новый ML. Это новый UI для старого ML.

ОНТОЛОГИЯ > МОДЕЛИ

Без единой сущности игрока (PlayerResolver, 14.7K игроков, 47K TM-профилей сведены) все слои разваливаются.

ЭМПИРИКА > ТЕОРИЯ

Каждое крупное решение — через эксперимент. Fat Context побил Zero Preload в A/B. Байес выиграл у усреднения.

СЛОИ > МОНОЛИТ

Попытка закрыть всё одной моделью = провал. Классическая статистика, Байес, векторный поиск, LLM — каждый на своём месте.